BẢN KÊ KHAI CÔNG CỤ AI, BỘ DỮ LIỆU, API, THƯ VIỆN

MÃ NGUỒN MỞ VÀ PHẦN VIỆC DO ĐỘI TỰ XÂY DỰNG

Dự án LUMOHUB — Công nghệ LUMO

Tài liệu này ghi nhận đầy đủ và chi tiết các công cụ AI, bộ dữ liệu, API, thư viện mã nguồn mở, cũng như các thành phần tự phát triển được sử dụng trong quá trình xây dựng và vận hành hệ thống LUMOHUB. Thông tin được cập nhật định kỳ và phản ánh đúng thực trạng triển khai tại thời điểm lập tài liệu.

Đơn vị: Công ty Luminos Technology • Ngày lập: Tháng 9/2026 • Phiên bản: 1.0

PHẦN I. CÔNG CỤ VÀ NỀN TẢNG AI

Danh sách các công cụ AI, nền tảng hỗ trợ lập trình, sinh nội dung (văn bản/hình ảnh) được đội ngũ sử dụng trong các giai đoạn phát triển và vận hành dự án.

STT	Tên công cụ / Thành phần	Phiên bản	Nguồn gốc / Nhà cung cấp	Vai trò / Mục đích sử dụng	Ghi chú
1	Claude 3.5 Sonnet	Latest	Anthropic	Mô hình LLM chính cho các tác vụ suy luận phức tạp, phân tích dữ liệu, lập trình, hỗ trợ thiết kế hệ thống AI.	API dùng chung; Miễn phí giới hạn cơ bản.
2	GitHub Copilot	Latest	GitHub / Microsoft	Gợi ý code tự động trong quá trình lập trình, tăng tốc phát triển phần mềm cho toàn đội.	Thuê bao cá nhân / tổ chức.
3	ChatGPT (GPT-4o)	GPT-4o	OpenAI	Hỗ trợ brainstorming, viết tài liệu, review code, tạo test case, giải thích thuật toán.	API có giới hạn; phù hợp tác vụ ngắn.
4	Gemini 1.5 Pro / Flash	1.5 Pro / Flash	Google AI	Mở rộng context window cho xử lý tài liệu dài; tích hợp Google ecosystem.	Miễn phí hạn chế; API trả phí.
5	Cursor AI	Latest	Cursor	IDE tích hợp AI cho lập trình viên; hỗ trợ chỉnh sửa multi-file, refactor, debug thông minh.	Đang dùng làm IDE chính.
6	DALL·E 3	3	OpenAI	Sinh hình ảnh minh họa cho tài liệu, bài trình bày, mockup UI.	Qua API OpenAI.
7	Midjourney	Latest	Midjourney	Tạo hình ảnh nghệ thuật, concept art, moodboard cho dự án.	Thuê bao Discord.
8	Leonardo AI	Latest	Leonardo.ai	Sinh ảnh game-style, kiến trúc, prototype; thay thế Midjourney khi cần mở rộng.	Miễn phí / trả phí.
9	Meta AI (Llama 3)	Llama 3.1 70B	Meta	Mô hình open-weight cho fine-tuning nội bộ; thử nghiệm RAG pipeline.	Tự host hoặc qua API.
10	Codeium	Latest	Codeium	Gợi ý code miễn phí, tích hợp Vim/VSCode; phòng khi Copilot không khả dụng.	Miễn phí, không giới hạn.

Ghi chú: Các công cụ được đánh giá định kỳ về hiệu quả và chi phí. Claude 3.5 Sonnet và Cursor AI là hai công cụ được sử dụng thường xuyên nhất.

PHẦN II. BỘ DỮ LIỆU

Các bộ dữ liệu được sử dụng cho huấn luyện (pretraining, fine-tuning), nghiên cứu và xây dựng ứng dụng AI nội bộ. Nguồn gốc, dung lượng và phạm vi sử dụng được ghi nhận rõ ràng.

STT	Tên bộ dữ liệu	Dung lượng	Nguồn / Nhà cung cấp	Mục đích sử dụng	Ghi chú
1	Common Crawl	~250 TB	commoncrawl.org	Dữ liệu huấn luyện LLM; crawl web quy mô lớn.	Open; dùng cho pretraining.
2	The Pile	825 GB	EleutherAI	Dữ liệu đa dạng cho nghiên cứu LLM; gồm arXiv, GitHub, Wikipedia, v.v.	Open; reference dataset.
3	FineWeb (Edu)	15T tokens	HuggingFace /□□	Dữ liệu web chất lượng cao, đã lọc cho giáo dục; dùng huấn luyện mô hình.	CC-BY license.
4	Vietnamese Open Pretraining (VIPO)	~20 GB	VinAI / CCM□	Corpus tiếng Việt quy mô lớn cho pretrain model tiếng Việt.	Miễn phí nghiên cứu.
5	OSCVN Dataset	~5 GB	Open Vietnamese NLP	Dữ liệu tiếng Việt có nhãn: NER, POS, sentiment, QA.	Open; dùng fine-tuning NLP.
6	Lao-English / Viet-Lao Parallel	~200 MB	OPUS / self-collected	Dữ liệu song ngữ cho huấn luyện mô hình dịch thuật Lào–Anh–Việt.	Cần clean và deduplicate.
7	ViHealthQA	~1.5 MB	UIT / Open Vietnamese NLP	Câu hỏi–trả lời y tế tiếng Việt; dùng fine-tune chatbot y tế.	Open; dùng thử nghiệm RAG.
8	Custom Collected (Lumohub internal)	Đang thu thập	Lumohub	Dữ liệu riêng: tài liệu kỹ thuật, tài liệu pháp lý, dữ liệu người dùng ẩn danh.	Cần tuân thủ GDPR/PDPD.

Ghi chú: Việc sử dụng dữ liệu tuân thủ các quy định pháp luật về bảo vệ dữ liệu cá nhân (GDPR, PDPD). Dữ liệu nội bộ của Lumohub được ẩn danh hóa trước khi dùng trong ML pipeline.

PHẦN III. API VÀ DỊCH VỤ BÊN THỨ BA

Các API và dịch vụ cloud bên thứ ba được tích hợp vào hệ thống LUMOHUB. Chi phí, giới hạn sử dụng và phương án dự phòng được ghi nhận để đảm bảo tính sẵn sàng.

STT	Tên API / Dịch vụ	Phiên bản	Nhà cung cấp	Mục đích sử dụng	Ghi chú
1	Anthropic Claude API	2023–06 / Latest	Anthropic	LLM inference chính; suy luận, phân tích, lập trình, tạo nội dung.	Có free tier; chi phí theo token.
2	OpenAI API (GPT-4o, DALL·E, TTS)	v1 / Latest	OpenAI	GPT-4o cho conversation; DALL·E cho sinh ảnh; TTS cho text-to-speech.	Có free tier; chi phí theo token.
3	Google Gemini API	v1beta / Latest	Google AI Studio	LLM với context window 1M token; thử nghiệm RAG trên tài liệu dài.	Miễn phí hạn chế; API key cần thiết.
4	Hugging Face Inference API	Latest	HuggingFace	Truy cập hàng nghìn model: embedding, summarization, translation, vision.	Miễn phí cơ bản; pro tier cho tốc độ cao.
5	Replicate API	Latest	Replicate	Chạy model open-source (Llama, Stable Diffusion, FLUX) không cần server.	Trả phí theo giây GPU.
6	GROQ API	Latest	GROQ	Inference LLM tốc độ cao, low latency; phù hợp real-time chat.	Miễn phí; rất nhanh.

STT	Tên API / Dịch vụ	Phiên bản	Nhà cung cấp	Mục đích sử dụng	Ghi chú
7	Cloudflare Workers AI	Latest	Cloudflare	Chạy AI model edge; embedding, summarization gần người dùng.	Miễn phí tier; tính phí egress.
8	SerpAPI (Google Search)	Latest	SerpAPI	Truy vấn Google Search qua API; dùng cho real-time RAG và web search.	100 searches miễn phí/tháng.
9	Firebase / Supabase API	Latest	Google / Supabase	Backend-as-a-Service: auth, database, storage, functions, realtime sync.	Free tier đủ cho prototype.
10	SendGrid / Resend API	v3 / Latest	Twilio SendGrid / Resend	Gửi email transactional và marketing; webhook nhận email reply.	Free 100 emails/ngày.

Ghi chú: Nên triển khai circuit breaker và fallback khi dùng API bên thứ ba. GROQ và Cloudflare Workers AI là hai lựa chọn miễn phí tốc độ cao đang được đánh giá.

PHẦN IV. THƯ VIỆN VÀ FRAMEWORK MÃ NGUỒN MỞ

Các thư viện và framework mã nguồn mở đóng vai trò nền tảng trong kiến trúc hệ thống LUMOHUB, từ LLM orchestration đến xử lý dữ liệu và triển khai model.

STT	Tên thư viện / Framework	Phiên bản	Nguồn / Tác giả	Mục đích sử dụng	Ghi chú
1	LangChain / LangGraph	0.3 / 0.4	LangChain Inc.	Xây dựng pipeline LLM: RAG, agents, chains, memory; tích hợp vector DB.	Đang dùng; có langgraph cho complex workflows.
2	LlamaIndex	0.10+	LlamaIndex	RAG framework chuyên biệt; index tài liệu, query engine, data connectors.	Phù hợp retrieval-heavy apps.
3	FAISS / ChromaDB / Qdrant	Latest	Meta / Chroma / Qdrant	Vector database cho semantic search và embedding storage.	FAISS offline; Chroma dev; Qdrant cloud/self-host.
4	sentence-transformers	3.x	Sentence-Transformers / SBERT	Tạo text embedding chất lượng cao cho retrieval và similarity search.	Dùng model 'paraphrase-multilingual-MiniLM-L12-v2'.
5	scikit-learn	1.5+	scikit-learn developers	ML cổ điển: classification, clustering, regression, feature engineering.	Dùng cho baseline model và evaluation.
6	PyTorch / Transformers	2.x / 4.x	Meta / HuggingFace	Fine-tuning LLM, training custom model, inference pipeline.	Cần GPU cho training; dùng bitsandbytes cho quantization.
7	vLLM	0.6+	vLLM Project	High-throughput LLM inference; PagedAttention, continuous batching.	Cần cho serving model tự host.
8	OpenCV	4.10+	OpenCV team	Xử lý ảnh/video: detect, crop, resize, format conversion, OCR pre-processing.	Python bindings.
9	Tesseract OCR	5.x	Google / UB-Mannheim	OCR nhận dạng ký tự từ ảnh/scan tài liệu tiếng Việt và tiếng Lào.	Cần fine-tune cho tiếng Việt/Lào.
10	ElevenLabs / Coqui TTS	Latest	ElevenLabs / Coqui	Text-to-Speech đa ngôn ngữ; tạo giọng nói cho chatbot và ứng dụng.	ElevenLabs trả phí; Coqui open-source.
11	Streamlit / Gradio	Latest	Streamlit / Gradio	Build UI nhanh cho demo, internal tools, proof-of-concept.	Dùng Streamlit cho dashboard; Gradio cho model serving.
12	FastAPI / uvicorn	0.115+ / 0.30+	Tiang Sommer / Starlette	Backend API server cho microservice AI, webhook, REST endpoints.	Async, auto-docs, Pydantic validation.
13	Pydantic / Dataclass	2.x	Samuel Colvin	Data validation và serialization; định nghĩa schema cho API request/response.	Dùng cho tất cả data models.
14	SQLAlchemy / Alembic	2.x	SQLAlchemy team	ORM và database migration; tương thích PostgreSQL, SQLite.	Dùng async SQLAlchemy với asyncio.
15	pytest / pytest-asyncio	8.x	pytest-dev	Unit test và integration test cho LLM pipeline, API, database operations.	Fixtures cho mock LLM responses.

Ghi chú: Phiên bản thư viện được lock trong requirements.txt / pyproject.toml. LangChain và sentence-transformers là hai thư viện quan trọng nhất của tech stack.

PHẦN V. THÀNH PHẦN TỰ XÂY DỰNG

Các thành phần phần mềm do đội ngũ Lumohub tự phát triển, bao gồm cả sản phẩm hoàn thiện và các module đang trong giai đoạn thử nghiệm. Đây là tài sản trí tuệ cốt lõi của công ty.

STT	Tên thành phần	Trạng thái	Người phụ trách	Mô tả chức năng	Công nghệ
1	Lumohub RAG Pipeline	Đang phát triển	Lumohub Dev Team	Hệ thống Retrieval-Augmented Generation tùy chỉnh: chunking, embedding, reranking, hybrid search (BM25 + vector). Hỗ trợ tiếng Việt và tiếng Lào.	LangChain, ChromaDB, sentence-transformers, FastAPI
2	Vietnamese / Lao Text Processor	Đang phát triển	Lumohub Dev Team	Bộ xử lý ngôn ngữ tự nhiên: tokenization, normalization, stopword, stemming cho tiếng Việt và tiếng Lào. Chuẩn hóa Unicode, xử lý font cũ.	underthesea, pyvi, PyICU, custom rules
3	Document OCR & Extraction Pipeline	Proof of Concept	Lumohub Dev Team	Pipeline nhận dạng và trích xuất nội dung từ tài liệu scan/PDF: OCR → layout detection → table extraction → entity recognition.	Tesseract OCR, PDFPlumber, OpenCV, LayoutLM
4	Lumohub Chatbot Framework	Đang phát triển	Lumohub Dev Team	Framework chatbot đa ngôn ngữ (VN, LO, EN): conversation management, context tracking, tool calling, multi-turn memory, guardrails.	LangGraph, Claude API, Firebase
5	Lumohub Analytics Dashboard	Proof of Concept	Lumohub Dev Team	Dashboard giám sát: usage metrics, token consumption, latency, error rates, user feedback. Real-time update.	Streamlit, Plotly, PostgreSQL, Redis
6	Lumohub API Gateway & Auth	Đang phát triển	Lumohub Dev Team	API gateway tập trung: authentication (JWT + OAuth2), rate limiting, request logging, abuse detection, API versioning.	FastAPI, Firebase Auth, Redis, PostgreSQL
7	Lumohub Data Pipeline (ETL)	Proof of Concept	Lumohub Dev Team	Pipeline xử lý dữ liệu: thu thập → clean → transform → store. Hỗ trợ incremental update, deduplication, data quality checks.	Python, Pandas, PostgreSQL, Apache Airflow
8	Lumohub Multimodal Agent	Ý tưởng / Lên kế hoạch	Lumohub Dev Team	Agent đa phương thức: kết hợp LLM + vision + audio + tool use. Xử lý input ảnh, âm thanh, văn bản trong một conversation.	Claude API, LangChain multimodal, Whisper
9	Lumohub Fine-tuned Models	Ý tưởng / Lên kế hoạch	Lumohub Dev Team	Fine-tune Llama 3.1 hoặc Phi-3 cho ngữ cảnh Lào–Việt. Dataset riêng thu thập từ tài liệu pháp lý, y tế, kỹ thuật.	PyTorch, LoRA, QLoRA, vLLM
10	Lumohub CI/CD & MLOps Pipeline	Đang phát triển	Lumohub Dev Team	CI/CD cho model deployment: automated testing, model versioning (DVC/MLflow), A/B testing, canary rollout, rollback.	GitHub Actions, Docker, DVC, MLflow

Ghi chú: Trạng thái: (1) Hoàn thành – đã triển khai production, (2) Đang phát triển – trong giai đoạn active development, (3) Proof of Concept – đang thử nghiệm tính khả thi, (4) Ý tưởng/Lên kế hoạch – chưa bắt đầu triển khai. Mã nguồn các thành phần hoàn thành được quản lý trên GitHub private repository.